

Arquitecturas y estrategias avanzadas para el manejo de conjuntos de datos de imágenes desbalanceados en sistemas de visión por computadora

La efectividad de los modelos de aprendizaje profundo en visión por computadora está intrínsecamente ligada a la calidad, diversidad y distribución de los datos de entrenamiento.¹ En el entorno de producción actual, caracterizado por la transición hacia paradigmas de IA centrada en los datos (Data-Centric AI), el manejo de distribuciones desbalanceadas se ha convertido en una competencia crítica para los expertos senior en ML y arquitectos de MLOps.³ El desbalance de datos, manifestado comúnmente como distribuciones de cola larga (long-tailed distributions), ocurre cuando unas pocas clases dominantes (clases cabeza) poseen la gran mayoría de las muestras, mientras que una multitud de clases críticas (clases cola) están severamente subrepresentadas.¹ Este fenómeno no es una anomalía estadística, sino una característica estructural de dominios como el diagnóstico médico, el control de calidad industrial y la detección de fraudes, donde los eventos de interés son, por definición, poco frecuentes.²

Taxonomía y naturaleza del desbalance en datos visuales

El desbalance en visión por computadora se manifiesta de diversas formas, afectando desde la clasificación de imágenes hasta la segmentación semántica y la detección de objetos.¹ En la clasificación binaria, la disparidad puede ser extrema; por ejemplo, en la detección de fallos en redes eléctricas o derrames de petróleo, la clase de interés puede representar menos del 0.1% del volumen total de datos capturados por sensores visuales.² En problemas multiclase, el desbalance suele seguir una distribución de ley de potencia, lo que dificulta que el modelo generalice características discriminatorias para las clases en la cola de la distribución sin verse abrumado por los gradientes de las clases mayoritarias.²

Dominio Industrial	Tipo de Clase Minoritaria	Prevalencia Estimada	Impacto del Sesgo de Clase
Salud Digital	Lesiones raras en	< 1%	Diagnósticos omitidos

	radiografías		(falsos negativos)
Manufactura	Defectos de superficie (grietas, poros)	< 0.5%	Despliegue de componentes estructurales fallidos
Finanzas/Seguridad	Imágenes de transacciones fraudulentas	< 0.2%	Pérdidas económicas masivas por fraude
Vehículos Autónomos	Peatones en condiciones de baja visibilidad	< 2%	Riesgos críticos para la seguridad vial
Agricultura de Precisión	Brotes de plagas específicas o deficiencias	< 5%	Pérdida de cosechas por falta de intervención

2

Desde una perspectiva técnica, el desbalance introduce el problema de la "ilusión de precisión", donde un modelo puede lograr una exactitud del 99% simplemente prediciendo siempre la clase mayoritaria, fallando completamente en la tarea para la que fue diseñado.¹¹ Para un experto senior, esto implica la necesidad de rediseñar no solo el proceso de entrenamiento, sino también los marcos de evaluación y monitoreo continuo.¹⁴

Estrategias de rebalanceo a nivel de datos

Las intervenciones a nivel de datos buscan transformar el conjunto de entrenamiento antes de que el proceso de optimización comience, con el objetivo de presentar al modelo una distribución más equitativa o informativa.¹

Muestreo heurístico y síntesis en el espacio de características

Las técnicas clásicas de re-muestreo incluyen el submuestreo de la clase mayoritaria y el

sobremuestreo de la clase minoritaria.¹² El submuestreo aleatorio, aunque reduce la carga computacional, corre el riesgo de eliminar muestras que contienen variaciones críticas de la clase mayoritaria, debilitando la frontera de decisión.¹² El sobremuestreo aleatorio, al duplicar imágenes, a menudo conduce al sobreajuste (overfitting), ya que el modelo simplemente memoriza ejemplos específicos en lugar de aprender una representación generalizable.¹²

Para mitigar esto, técnicas como SMOTE (Synthetic Minority Over-sampling Technique) y ADASYN (Adaptive Synthetic Sampling) generan muestras sintéticas mediante la interpolación en el espacio de características.¹⁵ En visión por computadora, esto se realiza típicamente sobre los vectores latentes extraídos por un codificador (encoder), dado que la interpolación en el espacio de píxeles carece de coherencia semántica.¹⁹ La generación de una nueva muestra x_{new} se basa en la relación lineal entre una muestra x_i y su vecino más cercano x_{nn} :

$$x_{new} = x_i + \lambda \cdot (x_{nn} - x_i)$$

donde λ es un factor de escala aleatorio.¹⁹ ADASYN mejora este proceso al asignar pesos a las muestras de la clase minoritaria basándose en su dificultad de aprendizaje, generando más datos en áreas donde la densidad de la clase mayoritaria es alta y, por ende, la confusión es probable.¹⁵

Aumento de datos avanzado y regularización de mezclas

El aumento de datos tradicional (rotación, traslación, cambios de color) actúa como una forma de regularización implícita que mejora la robustez del modelo ante variaciones del mundo real.²¹ Sin embargo, el manejo del desbalance requiere técnicas más agresivas que alteren la composición misma de las imágenes de entrenamiento.¹¹

Técnica de Aumento	Mecanismo de Acción	Beneficio para Desbalance
Mixup	Combina dos imágenes y etiquetas mediante media ponderada	Suaviza las fronteras de decisión y reduce la memorización
CutMix	Reemplaza parches de una imagen con parches de otra	Fuerza al modelo a enfocarse en características locales

Mosaic	Combina cuatro imágenes en una sola vista	Mejora la detección de objetos pequeños en contextos variados
Random Erasing	Oculta parches aleatorios de la imagen	Previene la dependencia excesiva de una sola característica
AugMix	Mezcla múltiples transformaciones con pérdida de consistencia	Mejora la robustez ante cambios de iluminación y ruido

11

El uso de Mixup en distribuciones de cola larga ha evolucionado hacia el "Mixup de decaimiento progresivo".¹⁸ Esta estrategia emplea dos mecanismos de muestreo independientes: uno basado en instancias (que sigue la distribución original) y otro basado en clases (que equilibra las muestras de forma artificial).¹⁸ Durante el entrenamiento, un coeficiente de mezcla lineal ρ ajusta dinámicamente el peso de cada rama:

$$\rho = 1 - \frac{T_{epoch}}{T_{max}}$$

donde T_{epoch} es la época actual y T_{max} el total.¹⁸ Esto permite que el modelo aprenda primero representaciones genéricas y potentes de las clases mayoritarias, para luego especializarse gradualmente en la discriminación de las clases minoritarias, evitando el daño a las características generales que a menudo causa un balanceo prematuro.¹⁸

Innovaciones en funciones de pérdida y aprendizaje sensible al costo

Cuando la manipulación de datos es insuficiente, la re-arquitectura de la función de pérdida permite al optimizador "prestar más atención" a los errores en las clases poco representadas.¹¹

Focal Loss y el direccionamiento hacia ejemplos difíciles

La entropía cruzada estándar es vulnerable al desbalance porque la pérdida acumulada de muchos ejemplos "fáciles" de la clase mayoritaria puede abrumar los gradientes generados por los pocos ejemplos de la clase minoritaria.⁸ La Focal Loss aborda este problema introduciendo un factor de modulación que reduce el peso de las muestras correctamente clasificadas con alta confianza.⁸ La función se expresa matemáticamente como:

$$L_{FL}(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

donde γ es el parámetro de enfoque (normalmente $\gamma = 2$) y α_t es un factor de balanceo de clase.⁸ A medida que p_t se acerca a 1 (ejemplo fácil), el término $(1 - p_t)^\gamma$ tiende a cero, descartando efectivamente la contribución de esa muestra a la actualización de los pesos.⁸ Esto es particularmente efectivo en la detección de objetos denso, donde el desbalance entre el fondo y los objetos pequeños es extremo.²⁶

Dice Loss y métricas de superposición en segmentación médica

En la segmentación de imágenes médicas, las estructuras patológicas (como microcalcificaciones o tumores incipientes) a menudo representan una fracción minúscula del volumen total de píxeles o vóxeles.⁶ La Dice Loss se ha convertido en el estándar de oro para estos casos, ya que mide directamente la superposición entre el área predicha y la verdad de referencia, siendo inmune al tamaño absoluto de la región.⁶ La fórmula de Dice se basa en:

$$DSC = \frac{2|X \cap Y|}{|X| + |Y|}$$

No obstante, la Dice Loss pura puede sufrir de inestabilidad y mala calibración de probabilidad.⁶ Para solucionar esto, marcos como el "Unified Focal Loss" integran jerárquicamente las propiedades de Dice y Focal Loss, permitiendo una convergencia robusta incluso en escenarios de desbalance severo donde las regiones de interés están fragmentadas.⁶

Pesado dinámico y pérdida balanceada por clase

Más allá de los pesos fijos basados en la frecuencia inversa, la pérdida balanceada por clase (Class-Balanced Loss) introduce el concepto del "número efectivo de muestras".³⁰ Este enfoque reconoce que, a medida que aumenta el número de muestras en una clase, el beneficio marginal de información disminuye debido a la redundancia.³⁰ La pérdida se escala por un factor $(1 - \beta)/(1 - \beta^{n_i})$, donde n_i es el número de muestras y β es un hiperparámetro que controla la tasa de redundancia.³⁰ Variantes más recientes, como la FCB Loss (Forgetting-based Class-Balanced Loss), integran el concepto de "olvido de ejemplos"

para identificar dinámicamente qué muestras son verdaderamente informativas, ajustando los pesos de la pérdida en tiempo real durante el entrenamiento.³⁰

Estrategias estructurales y arquitecturas de desacoplamiento

Un hallazgo fundamental en la investigación de aprendizaje de cola larga es que la representación de características y la clasificación final se ven afectadas de manera diferente por el desbalance.³¹

Desacoplamiento de representación y clasificación

El paradigma de desacoplamiento propone que el extractor de características (backbone) debe entrenarse preferiblemente en la distribución original para capturar la mayor riqueza semántica posible, mientras que el clasificador (capa lineal final) debe ajustarse utilizando estrategias de balanceo.³¹ Estudios extensos en ImageNet-LT y iNaturalist demuestran que este enfoque supera a las pérdidas diseñadas meticulosamente que intentan entrenar ambos componentes simultáneamente.³¹

Para rebalancear el clasificador, se emplean técnicas como:

1. **Ajuste de Logits (Logit Adjustment):** Aplica una corrección a las salidas del modelo basada en las frecuencias de clase de los datos de entrenamiento para compensar el sesgo hacia la clase mayoritaria.¹⁰
2. **Normalización de pesos ($\mathcal{T}$ -normalization):** Escala los pesos de la capa del clasificador para equilibrar las normas de los vectores de cada clase, evitando que las clases mayoritarias tengan una influencia desproporcionada en la frontera de decisión.³¹

Redes de Rama Bilateral (BBN) y Model Rebalancing (MORE)

Las Redes de Rama Bilateral (BBN) implementan este desacoplamiento de forma dinámica en una sola arquitectura.¹⁸ Una rama de aprendizaje de representación utiliza muestreo por instancias para preservar el colector de datos global, mientras que una rama de rebalanceo utiliza muestreo por clases para enfatizar la cola.¹⁸ Ambas ramas comparten el mismo extractor de características pero tienen cabezas de clasificación distintas que se fusionan progresivamente.¹⁸

El marco MORE (Model Rebalancing) lleva esto un paso más allá al reequilibrar directamente el espacio de parámetros del modelo.¹⁰ MORE introduce componentes de bajo rango que median la asignación de la capacidad de la red, asegurando que las clases minoritarias reciban suficiente "capacidad neuronal" para representar sus sutilezas sin degradar el rendimiento de las clases cabeza.¹⁰ Este ajuste se guía por una pérdida de discrepancia adaptada y un programa de pesado sinusoidal que garantiza una transición suave durante el ciclo de

entrenamiento.¹⁰

El papel de la IA Generativa en la síntesis de datos para visión

La aparición de modelos generativos profundos ha revolucionado el manejo de la escasez de datos, permitiendo pasar de un aumento de datos reactivo a una síntesis proactiva y de alta fidelidad.⁴

GANs y la restauración de equilibrio adversario

Las Redes Neuronales Adversarias (GANs) han sido utilizadas ampliamente para generar imágenes realistas de clases raras.²² Modelos como ACGAN (Auxiliary Classifier GAN) y cGAN (Conditional GAN) permiten generar muestras bajo demanda para clases específicas, proporcionando un control granular sobre la distribución final del dataset.³⁴ Sin embargo, las GANs enfrentan desafíos persistentes en producción, como el colapso de modo (mode collapse), donde el generador produce variantes limitadas de la clase minoritaria, y la inestabilidad intrínseca del juego de suma cero entre el generador y el discriminador.³⁴

Modelos de Difusión y la estrategia DiffuLT

Los modelos de difusión, como DDPM y Stable Diffusion, ofrecen una alternativa superior en términos de diversidad y fidelidad visual.²³ A diferencia de las GANs, la difusión aprende a modelar la distribución de datos mediante un proceso iterativo de eliminación de ruido, lo que resulta en una captura más precisa de la variabilidad estadística de las clases cola.⁹

El pipeline DiffuLT (Diffusion model for Long-Tail recognition) representa el estado del arte en esta área.⁵ DiffuLT opera exclusivamente con datos "in-domain", eliminando la dependencia de modelos pre-entrenados externamente que podrían introducir sesgos ajenos o violar normativas de privacidad.⁵ El proceso consta de:

1. **Entrenamiento de Difusión Condicional:** Se entrena un modelo sobre el dataset desbalanceado original, incorporando etiquetas de clase como condiciones.⁵
2. **Generación de Proxy Balanceado:** El modelo genera muestras sintéticas para las clases que no alcanzan un umbral predefinido N_t .⁵
3. **Filtrado de Muestras Detrimentales:** Se utiliza la información intrínseca del dataset original para filtrar imágenes sintéticas que no superan un umbral de relevancia semántica.⁹
4. **Re-entrenamiento del Clasificador:** Se entrena un clasificador final sobre el dataset enriquecido utilizando una pérdida de entropía cruzada estándar.⁹

Característica	GANs en Producción	Modelos de Difusión	Aumento Tradicional
Fidelidad Visual	Muy alta (nítida)	Excelente (texturas ricas)	Limitada a la imagen base
Diversidad de Muestras	Media (riesgo de colapso)	Muy alta (estocástica)	Baja
Costo Computacional	Bajo (una sola pasada)	Alto (muestreo iterativo)	Despreciable
Estabilidad de Entrenamiento	Crítica / Difícil	Estable / Predecible	No aplica
Control Semántico	Basado en etiquetas/ruido	Guía por texto/negativos	Geométrico/Colorimétrico

5

Aprendizaje auto-supervisado (SSL) y representaciones robustas

El aprendizaje auto-supervisado (SSL) permite extraer características discriminatorias de los datos sin necesidad de etiquetas, lo que puede ser crucial para "pre-entrenar" modelos en conjuntos de datos donde las etiquetas son escasas para la mayoría de las clases.³⁸

El objetivo de "más de dos vistas" en aprendizaje contrastivo

El aprendizaje contrastivo tradicional (CSSL) suele basarse en la suposición de dos vistas de un mismo objeto.⁴¹ Sin embargo, investigaciones recientes indican que este marco puede ser insuficiente para capturar las sutilezas de las clases en la cola de la distribución.⁴² El marco MIMV (Multi-Image Multi-View) propone utilizar múltiples vistas para segregar explícitamente

las características intra e inter-discriminatorias.³⁹ Al maximizar la información mutua entre múltiples representaciones de clases minoritarias, el modelo aprende a identificar lo que hace única a una clase rara, incluso ante una escasez severa de muestras.³⁹

En el campo médico, el SSL ha demostrado una resiliencia notable.³⁸ El pre-entrenamiento SSL en imágenes médicas no etiquetadas, combinado con una inicialización en ImageNet, supera significativamente al pre-entrenamiento supervisado tradicional en tareas de dermatología y radiología de tórax bajo condiciones de desbalance severo.³⁸ Esto se debe a que el SSL obliga al modelo a aprender la estructura geométrica y textural intrínseca de las imágenes, proporcionando un cimiento sólido que no se ve sesgado prematuramente por la frecuencia de las etiquetas.³⁸

Métricas de evaluación y rigor estadístico para expertos senior

Para un Senior ML Engineer, reportar la exactitud (accuracy) en un dataset desbalanceado es un error fundamental.¹¹ La evaluación debe centrarse en la capacidad del modelo para discernir la clase minoritaria sin inundar el sistema con falsos positivos.¹²

Coeficiente de Correlación de Matthews (MCC)

El MCC se destaca como la métrica más equilibrada para la clasificación binaria, ya que integra todos los elementos de la matriz de confusión.⁴⁴ A diferencia del F1-score, que ignora los verdaderos negativos (TN), el MCC es simétrico e invariante al intercambio de etiquetas de clase.⁴³ Un MCC de +1 indica una predicción perfecta, mientras que 0 indica un rendimiento aleatorio.⁴³ Es especialmente útil en aplicaciones de salud y ciberseguridad, donde el costo de ignorar el "fondo" o las "transacciones normales" puede sesgar la percepción del éxito del modelo.⁴⁴

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

F1-Score, Precisión y Recall

El F1-score sigue siendo la métrica de facto en muchas aplicaciones industriales debido a su capacidad para equilibrar la precisión y la exhaustividad (recall) en una sola cifra.¹³ Sin embargo, los expertos deben estar atentos a la disparidad entre precisión y recall; en la detección de defectos, un recall bajo significa que productos defectuosos están llegando al cliente, mientras que una precisión baja significa que se está descartando material de calidad (costo operativo).⁴³

Curvas PR y AUC

Mientras que la curva ROC es útil para comparar la capacidad de discriminación general, la curva de Precisión-Recall (PR) es superior para visualizar el rendimiento en datasets donde la clase positiva es extremadamente rara.⁴³ Una caída temprana en la curva PR revela que el modelo pierde rápidamente su capacidad de predicción precisa a medida que intentamos capturar más muestras de la clase minoritaria, una visión crítica que la curva ROC a menudo oculta debido a la dominancia de los verdaderos negativos.⁴³

Métrica de Evaluación	Componentes de Matriz Utilizados	Escenario Recomendado
Balanced Accuracy	Recall de cada clase	Evaluación rápida y equilibrada multiclase
F1-Score	TP, FP, FN	Cuando los negativos no son la prioridad principal
MCC	TP, TN, FP, FN	Evaluación estadística rigurosa de alta fidelidad
Cohen’s Kappa	Acuerdo real vs. azar	Diagnóstico médico y anotación por expertos
Log Loss	Probabilidades predichas	Modelos donde la calibración de confianza es clave

Perspectiva de LLMOps: Pipeline y ciclo de vida en producción

Desde el rol de Senior ML/AI & LLMOps Expert, la gestión del desbalance debe estar integrada

en la infraestructura misma de la plataforma de IA.¹⁴

Monitoreo continuo e ingesta de datos

El primer paso en un workflow de MLOps para visión por computadora es el monitoreo activo de la distribución de clases durante la ingesta.¹² Herramientas como Evidently AI o WhyLabs pueden detectar derivas de datos (data drift) y cambios en la prevalencia de clases antes de que afecten el rendimiento en producción.¹⁵ El versionado de datos mediante DVC o Pachyderm es imperativo para asegurar la reproducibilidad de los experimentos donde se aplicaron técnicas de balanceo sintético o re-muestreo.¹⁵

Aprendizaje Activo (Active Learning) y Bucle de Retroalimentación

El aprendizaje activo es quizás la estrategia más eficiente en términos de costo para combatir el desbalance en producción.⁵⁰ En lugar de etiquetar millones de imágenes, el pipeline selecciona solo aquellas que son "informativas" para el modelo.⁵² Las estrategias incluyen:

1. **Muestreo por Incertidumbre (Uncertainty Sampling):** Selecciona imágenes donde el modelo tiene baja confianza o alta entropía en su predicción.⁵²
2. **Consulta por Comité (Query-by-Committee):** Utiliza un ensamble de modelos y etiqueta las imágenes donde las predicciones discrepan significativamente.⁵²
3. **Muestreo por Diversidad (Diversity Sampling):** Utiliza embeddings visuales para asegurar que las nuevas muestras etiquetadas cubran áreas del espacio de características que el modelo aún no domina.⁵²

Un ejemplo icónico es el sistema de Tesla para su piloto automático: cuando el modelo de visión discrepa con la intervención del conductor (evento raro/cola larga), el sistema registra el evento, lo sube a la nube, se etiqueta y se integra en el siguiente ciclo de entrenamiento, cerrando el bucle de validación continua.⁵⁰

IA Centrada en los Datos (Data-Centric AI)

El enfoque senior se desplaza del ajuste de hiperparámetros hacia la mejora sistemática de los datos.³ La filosofía Data-Centric AI (DCAI) trata al dataset como el producto principal.⁴ Esto implica implementar protocolos de limpieza de ruido, detectar errores de etiquetado en las clases minoritarias (donde un solo error tiene un impacto enorme en el gradiente) y utilizar modelos generativos para "llenar los huecos" en las distribuciones de cola larga de manera sistemática y auditable.⁴

Desafíos de implementación en el Edge y computación distribuida

Desplegar modelos robustos contra el desbalance en dispositivos de borde (edge devices) introduce restricciones adicionales de latencia y memoria.⁷

1. **Restricciones de Ancho de Banda:** En entornos industriales, no siempre es posible subir todas las imágenes raras a la nube para re-entrenamiento debido a la latencia o falta de conectividad.⁷ Esto requiere estrategias de "On-device Learning" o selección inteligente de muestras para subida.⁷
2. **Aprendizaje Federado:** Permite entrenar modelos a través de múltiples dispositivos sin mover los datos brutos, lo que ayuda a recolectar patrones de clases raras de diferentes fuentes geográficas o institucionales manteniendo la privacidad.⁵⁰
3. **Compresión de Modelos:** Técnicas como la destilación de conocimiento (knowledge distillation) pueden transferir el conocimiento de un modelo grande entrenado con técnicas generativas pesadas (como difusión) a un modelo ligero optimizado para el borde, preservando la capacidad de reconocer clases minoritarias.⁷

Conclusiones y recomendaciones estratégicas

El manejo de conjuntos de datos desbalanceados en visión por computadora es un desafío multidisciplinario que requiere una combinación equilibrada de manipulación de datos, diseño de funciones de pérdida y arquitectura de pipelines de producción.¹

Para un experto senior, la recomendación principal es adoptar un enfoque jerárquico:

- **En la fase inicial de prototipado:** Priorizar técnicas de bajo costo como el pesado de clases y aumentos de datos tradicionales (Mixup, CutMix).¹⁷
- **En la fase de optimización de rendimiento:** Evaluar el desacoplamiento de la representación y el clasificador, y considerar la síntesis de datos mediante modelos de difusión si la diversidad de la clase minoritaria es insuficiente.⁹
- **En la fase de escalado y producción:** Implementar bucles de aprendizaje activo y monitoreo de deriva de distribución para asegurar que el modelo se adapte continuamente a nuevos "casos de borde" en el mundo real.¹⁴

La transición hacia sistemas de visión verdaderamente confiables depende de la capacidad de los equipos de ML para abandonar la métrica de exactitud global y abrazar un rigor estadístico centrado en la exhaustividad y la precisión sobre los eventos críticos, garantizando que la inteligencia artificial sea no solo precisa en promedio, sino robusta en las excepciones.¹¹

Obras citadas

1. [2502.08960] A Comprehensive Survey on Imbalanced Data Learning - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/abs/2502.08960>
2. A Comprehensive Survey on Imbalanced Data Learning - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/html/2502.08960v2>
3. Data-Centric AI - van der Schaar Lab, fecha de acceso: abril 8, 2026, <https://www.vanderschaar-lab.com/data-centric-ai/>
4. Data-Centric AI: How Generative AI Can Enhance Data Quality and Diversity - [x]cube LABS, fecha de acceso: abril 8, 2026,

- <https://www.xcubelabs.com/blog/data-centric-ai-development-how-generative-ai-can-enhance-data-quality-and-diversity/>
5. DiffuLT: How to Make Diffusion Model Useful for Long-tail Recognition - alphaXiv, fecha de acceso: abril 8, 2026, <https://www.alphaxiv.org/overview/2403.05170>
 6. Unified Focal loss: Generalising Dice and cross entropy-based losses to handle class imbalanced medical image segmentation. - Apollo, fecha de acceso: abril 8, 2026, <https://www.repository.cam.ac.uk/items/ebca5773-f526-4431-8328-c40841d19475>
 7. Build an end-to-end MLOps pipeline for visual quality inspection at the edge – Part 1 - AWS, fecha de acceso: abril 8, 2026, <https://aws.amazon.com/blogs/machine-learning/build-an-end-to-end-mlops-pipeline-for-visual-quality-inspection-at-the-edge-part-1/>
 8. Instance segmentation loss functions - SoftwareMill, fecha de acceso: abril 8, 2026, <https://softwaremill.com/instance-segmentation-loss-functions/>
 9. DiffuLT: How to Make Diffusion Model Useful for Long-tail Recognition - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/html/2403.05170v1>
 10. NeurIPS Poster Long-tailed Recognition with Model Rebalancing, fecha de acceso: abril 8, 2026, <https://neurips.cc/virtual/2025/poster/116487>
 11. Handling Imbalanced Datasets with MixUp, CutMix, and Focal Loss - Medium, fecha de acceso: abril 8, 2026, <https://medium.com/@ahmetbekirarslanalp/handling-imbalanced-datasets-with-mixup-cutmix-and-focal-loss-6b38d603da9b>
 12. Handling Imbalanced Data: A Practical Guide for Machine Learning and MLOps - Medium, fecha de acceso: abril 8, 2026, <https://medium.com/@rautyash121/handling-imbalanced-data-a-practical-guide-for-machine-learning-and-mlops-8c2dbfbe2127>
 13. Classification: Accuracy, recall, precision, and related metrics | Machine Learning, fecha de acceso: abril 8, 2026, <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall>
 14. fecha de acceso: abril 8, 2026, <https://medium.com/@rautyash121/handling-imbalanced-data-a-practical-guide-for-machine-learning-and-mlops-8c2dbfbe2127#:~:text=Handling%20Imbalanced%20Data%20in%20MLOps,resampling%20techniques%20in%20preprocessing%20pipelines>
 15. Handling Imbalanced Data in MLOps | by Soham ingale - Medium, fecha de acceso: abril 8, 2026, <https://medium.com/@ingalesoham7770/handeling-imbalanced-data-in-mlops-e4543868989e>
 16. How to Deal with Imbalanced Datasets in Computer Vision - Picsellia, fecha de acceso: abril 8, 2026, <https://www.picsellia.com/post/improve-imbalanced-datasets-in-computer-vision>
 17. Top 5 Strategies to Handle Imbalanced Data Classification - Numerous.ai, fecha

- de acceso: abril 8, 2026, <https://numerous.ai/blog/imbalanced-data-classification>
18. PeerJ A progressive decay Mixup data augmentation for long-tailed ..., fecha de acceso: abril 8, 2026, <https://peerj.com/articles/cs-3261/>
 19. Synthetic Data Augmentation for Imbalanced Tabular Data: A Comparative Study of Generation Methods - MDPI, fecha de acceso: abril 8, 2026, <https://www.mdpi.com/2079-9292/15/4/883>
 20. More Data or Better Algorithms: Latent Diffusion Augmentation for Deep Imbalanced Regression - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/html/2509.23240v1>
 21. Data Augmentation in Deep Learning | Programming Ocean Academy, fecha de acceso: abril 8, 2026, <https://www.programming-ocean.com/knowledge-hub/data-augmentation-atlas.php>
 22. Data Augmentation: From Basics to Super-Advanced Concepts | by Adnan Mazraeh, fecha de acceso: abril 8, 2026, <https://medium.com/@adnan.mazraeh1993/data-augmentation-from-basics-to-super-advanced-concepts-2a366c17489e>
 23. traditional augmentation versus deep generative diffusion augmentation for addressing class imbalance in chest x-ray classification - Utrecht University Student Theses Repository Home, fecha de acceso: abril 8, 2026, https://studenttheses.uu.nl/bitstream/handle/20.500.12932/45433/Master_project_Xinhao_Lan.pdf?sequence=1&isAllowed=y
 24. How to use CutMix and MixUp — Torchvision main documentation, fecha de acceso: abril 8, 2026, https://docs.pytorch.org/vision/main/auto_examples/transforms/plot_cutmix_mixup.html
 25. Synthetic Data Augmentation using Pre-trained Diffusion Models for Long-tailed Food Image Classification, fecha de acceso: abril 8, 2026, https://openaccess.thecvf.com/content/CVPR2025W/MTF/papers/Koh_Synthetic_Data_Augmentation_using_Pre-trained_Diffusion_Models_for_Long-tailed_Food_CVPRW_2025_paper.pdf
 26. Binary Classification: focal loss vs weighted cross entropy for handling imbalanced data, fecha de acceso: abril 8, 2026, https://www.researchgate.net/post/Binary_Classification_focal_loss_vs_weighted_cross_entropy_for_handling_imbalanced_data
 27. Computational Strategies for Handling Imbalanced Data in Machine Learning, fecha de acceso: abril 8, 2026, <https://isi-web.org/sites/default/files/2024-02/Handling-Data-Imbalance-in-Machine-Learning.pdf>
 28. An Analysis of Loss Functions for Heavily Imbalanced Lesion Segmentation - MDPI, fecha de acceso: abril 8, 2026, <https://www.mdpi.com/1424-8220/24/6/1981>
 29. Unified Focal loss: Generalising Dice and cross entropy-based losses to handle class imbalanced medical image segmentation - PMC, fecha de acceso: abril 8, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC8785124/>
 30. Towards robust long-tailed recognition: A class-balanced loss based on example

- forgetting, fecha de acceso: abril 8, 2026,
<https://www.aims sciences.org/article/doi/10.3934/mfc.2025028?viewType=HTML>
31. Decoupling Representation and Classifier for Long-Tailed Recognition - ResearchGate, fecha de acceso: abril 8, 2026,
https://www.researchgate.net/publication/336716333_Decoupling_Representation_and_Classifier_for_Long-Tailed_Recognition
 32. Long-tailed Recognition with Model Rebalancing - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/html/2510.08177v1>
 33. Generative Models for Synthetic Data: Transforming Data Mining in the GenAI Era - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/html/2508.19570v1>
 34. GANs vs. Diffusion Models: In-Depth Comparison and Analysis - Sapien, fecha de acceso: abril 8, 2026,
<https://www.sapien.io/blog/gans-vs-diffusion-models-a-comparative-analysis>
 35. A survey on generative adversarial networks for imbalance problems in computer vision tasks - PMC, fecha de acceso: abril 8, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC7845583/>
 36. [2403.05170] DiffuLT: How to Make Diffusion Model Useful for Long-tail Recognition - arXiv, fecha de acceso: abril 8, 2026,
<https://arxiv.org/abs/2403.05170>
 37. DiffuLT: Diffusion for Long-tail Recognition Without External Knowledge, fecha de acceso: abril 8, 2026,
https://proceedings.neurips.cc/paper_files/paper/2024/hash/de7858e3e7f9f0f7b2c7bfdc86f6d928-Abstract-Conference.html
 38. A Self supervised learning framework for imbalanced medical imaging datasets - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/html/2604.01947v1>
 39. A Self supervised learning framework for imbalanced medical imaging datasets - arXiv, fecha de acceso: abril 8, 2026, <https://arxiv.org/abs/2604.01947>
 40. Self-supervised Learning Framework for Imbalanced Positive-Unlabeled Data - Open Access LMU, fecha de acceso: abril 8, 2026,
https://epub.ub.uni-muenchen.de/92622/1/MA_Schweisthal_komp.pdf
 41. Maximally Useful and Minimally Redundant: The Key to Self Supervised Learning for Imbalanced Data - arXiv, fecha de acceso: abril 8, 2026,
<https://arxiv.org/html/2509.08469v2>
 42. [2509.08469] Maximally Useful and Minimally Redundant: The Key to Self Supervised Learning for Imbalanced Data - arXiv, fecha de acceso: abril 8, 2026,
<https://arxiv.org/abs/2509.08469>
 43. Understanding Model Evaluation Metrics for Image Classification - Akridata, fecha de acceso: abril 8, 2026,
<https://akridata.ai/blog/understanding-model-evaluation-metrics-for-image-classification/>
 44. The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation - PMC, fecha de acceso: abril 8, 2026,
<https://pmc.ncbi.nlm.nih.gov/articles/PMC6941312/>
 45. Understanding the Matthews Correlation Coefficient (MCC) in Machine Learning - KoshurAI, fecha de acceso: abril 8, 2026,

<https://koshurai.medium.com/understanding-the-matthews-correlation-coefficient-mcc-in-machine-learning-26e8049f8572>

46. Visualize Accuracy, F1-score and MCC with data imbalance case scenarios | by Lan Vu, fecha de acceso: abril 8, 2026, <https://medium.com/@lanvu3003/when-my-data-are-imbalanced-accuracy-f1-score-or-mcc-24d9baf424>
47. Mastering the F1 Score: A Practical Guide for Machine Learning Success - Lightly AI, fecha de acceso: abril 8, 2026, <https://www.lightly.ai/blog/f1-score>
48. Understanding F1 Score in Machine Learning - Tutorials Dojo, fecha de acceso: abril 8, 2026, <https://tutorialsdojo.com/understanding-f1-score-in-machine-learning/>
49. An Introduction to the F1 Score in Machine Learning | ml-articles - Wandb, fecha de acceso: abril 8, 2026, <https://wandb.ai/mostafaibrahim17/ml-articles/reports/An-Introduction-to-the-F1-Score-in-Machine-Learning--Vmldzo2OTY0Mzg1>
50. MLOps for Computer Vision: Keeping Data and Models in Sync - Objectways, fecha de acceso: abril 8, 2026, <https://objectways.com/blog/mlops-for-computer-vision-keeping-data-and-models-in-sync/>
51. Building an End-to-End Computer Vision MLOps Pipeline: A Practical Guide | by Sunusi Ibrahim Muhammad | Medium, fecha de acceso: abril 8, 2026, <https://medium.com/@sunusimuhammada/building-an-end-to-end-computer-vision-mlops-pipeline-a-practical-guide-974b2f6a6f81>
52. Active Learning for Imbalanced Classification: Empirical Insights, Iteration Scheduling, and LLM-Augmented Validation - IEEE Xplore, fecha de acceso: abril 8, 2026, <https://ieeexplore.ieee.org/iel8/6287639/10820123/11215701.pdf>
53. Deep Active Learning for Computer Vision: Past and Future - Emerald Insight, fecha de acceso: abril 8, 2026, <https://www.emerald.com/atsip/article/12/1/1/1331451/Deep-Active-Learning-for-Computer-Vision-Past-and>
54. The Practitioner Guide to Active Learning in Machine Learning - Lightly AI, fecha de acceso: abril 8, 2026, <https://www.lightly.ai/blog/active-learning-in-machine-learning>
55. Data-Centric AI: Prioritizing Data Quality over Model Complexity - ResearchGate, fecha de acceso: abril 8, 2026, https://www.researchgate.net/publication/390960117_Data-Centric_AI_Prioritizing_Data_Quality_over_Model_Complexity
56. Enhancing the Performance of Computer Vision Systems in Industry: A Comparative Evaluation Between Data-Centric and Model-Centric Artificial Intelligence - MDPI, fecha de acceso: abril 8, 2026, <https://www.mdpi.com/2079-9292/14/22/4366>
57. Building specialized AI without sacrificing intelligence: Nova Forge data mixing in action, fecha de acceso: abril 8, 2026, <https://aws.amazon.com/blogs/machine-learning/building-specialized-ai-without-sacrificing-intelligence-nova-forge-data-mixing-in-action/>